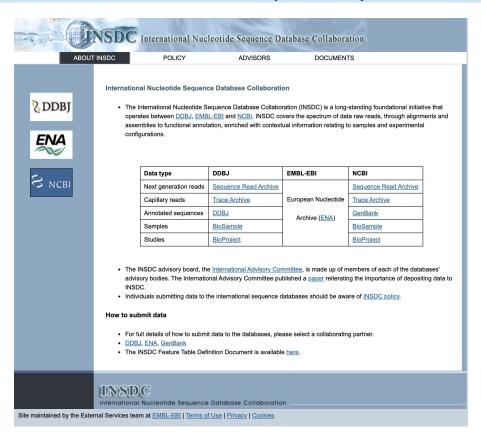
Module d'enseignement "Nature et culture 3 Licence Sciences et Humanités Aix-Marseille Université Novembre 2021

# Bases de données de séquences biologiques

# International Nucleotide Sequence Database Consortium (INSDC)

- Avant de publier un article scientifique qui repose sur des séquences, les biologistes sont tenus de déposer ces séquences dans l'une des trois bases de données internationales de référence:
  - NCBI (Etats-Unis)
  - EMBL-EBI-ENA (Europe)
  - DDBJ (Japon)
- Ces bases de données se sont organisées en un consortium : International Nucleotide Sequence Database Consortium (INSDC).
- Les séquences soumises à chaque base de donnée sont automatiquement copiées dans les deux autres.



https://www.insdc.org/

### NCBI Entrez

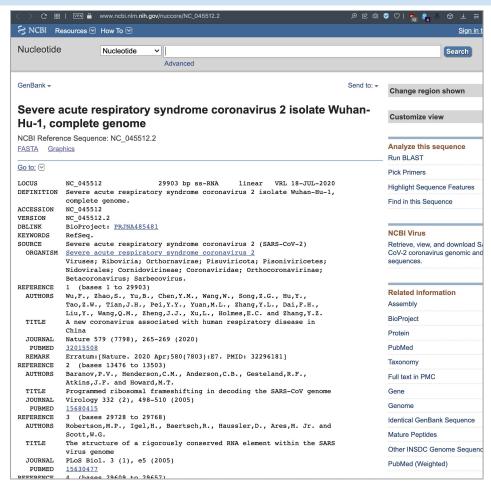
- Le National Center for Biotechnology Information (NCBI) est le plus grand centre international de référence pour les données biologiques.
- Via son site Web « Entrez », le NCBI donne accès à une série de bases de données pour différents types d'informations
  - Séquences nucléiques (ADN, ARN)
  - Génomes
  - Séquences protéiques
  - Taxonomie des espèces vivantes
  - Littérature biomédicale
  - **...**



Attention dbGaP submitters! Join us of November 3, 2021 at 12PM US easter

## NCBI genomes

 La section Genomes du NCBI permet d'accéder rapidement à l'information disponible pour les génomes complètement séquencés.



### Uniprot KB et Swiss-Prot KB

- https://www.uniprot.org/
- KB: knowledge base
- Uniprot KB vise à rassembler l'information sur toutes les séquences protéiques caractérisées par les biologistes.
- Swiss-Prot contient des séquences protéiques "annotées" par des biologistes. L'annotation consiste à associer à une séquence les connaissances résultant d'expérimentation.
  - Fonction de la protéine
  - Domaines structurels
  - Sites actifs (enzymes)



### Uniprot / Swiss-Prot KB

### Deux limitations à l'annotation

- Le nombre de publications augmente tellement qu'il n'est pas possible à l'équipe de Swiss-Prot de tout annoter
- Le nombre de séquences augmente de façon tellement rapide qu'il est impossible de toutes les caractériser expérimentalement

### TREMBL

- annotation automatique des séquences traduites de la base de données EMBL.
- Uniprot = Swiss-Prot + TREMBL
  - Swiss-Prot 580.000 séquences
  - □ TREMBL >200 millions!
- Conséquence: la vaste majorité des séquences sont annotées automatiquement, sans possibilité de les vérifier individuellement

# Number of entries in UniProtKB/Swiss-Prot 600k 500k 400k 200k 100k 19851988199119941997200020032006200920122015201820212024

